参考文献

[1] Giulio Starace, Oliver Jaffe, Dane Sherburn, James Aung, Jun Shern Chan, Leon Maksin, Rachel Dias, Evan Mays, Benjamin Kinsella, Wyatt Thompson, Johannes Heidecke, Amelia Glaese, and Tejal Patwardhan. Paperbench: Evaluating ai's ability to replicate ai research, 2025.

1 研究背景与目前系统现状

1.1 研究背景

对于蛋白质设计这类高代价任务而言，系统真正面对的难点不只是" 是否会调用工具 "，而在于以下几个方面：

- 任务链条长，且阶段之间存在强依赖关系；
- 不同阶段的计算代价和失败后果高度不对称；
- 运行过程中常常出现信息不充分、候选分歧、局部失败和恢复决策问题；
- 何时继续自动执行、何时切换策略、何时请求人工介入，本身就是关键问题。

因此，如果将毕设继续定义为"蛋白质设计助手"，其研究重点很容易停留在"任务分解、工具调用、结果输出"这一层面，即便加入了风险门控等系统。如果希望体现更明确的计算机相关的专业特征的话，我觉得可以把问题进一步上升为"高代价科学工作流的执行控制与治理"。

1.2 当前系统现状

从现有的系统设计来看，它已经形成了一个较为稳定的多 Agent 工作流执行系统。

首先，系统采用了显式有限状态机（FSM）作为运行核心，要求任务状态显式、状态转移合法且可记录，外部语义状态和内部执行状态均有明确定义。这意味着系统已经具备较好的执行一致性、可恢复性与可审计性基础。

其次，系统在角色划分上已经形成了较为清晰的职责边界：PlannerAgent 负责生成计划候选，ExecutorAgent 负责工具执行和恢复流程，SafetyAgent 负责评估，SummarizerAgent 负责结果汇总。这种结构表明系统已经具备典型多 Agent runtime 的雏形。

再次，系统已经围绕蛋白质设计任务构建了较为完整的阶段化流程，已经支持：

- S1 序列候选生成
- S2 结构投影
- S3 质量门控

- S4 基于结构条件的细化
- 分层 patch/replan 恢复机制

此外,系统已经具备 HITL(Human-in-the-loop)机制和恢复链设计,包括 `WAITING_*` 以及 $retry \to patch \to replan$ 的恢复顺序要求。这说明系统已经在工程层面充分考虑了可恢复执行和人工参与的问题。

最后，系统已经具备一定实验与评测基础。当前仓库中存在 `A0-A6` 纵向实验框架，用于从效果、机制、代价、治理维度评估系统表现，并支持复现与增量归因分析。这为后续研究提供了较好的实验基础。

1.3 对当前系统的整体评估

综合来看，当前系统已经具备：

- 较成熟的多 `Agent runtime` 骨架；
- 显式状态机与和恢复执行机制；
- 蛋白质设计的具体工作流场景；
- 实验框架和评测口径

但从毕设角度考虑，该系统也存在一个更关键的问题：其更像是一个完成度较高的执行平台，而不是一个核心算法问题已经被明确抽象出来的研究课题。

这一问题主要体现在三个方面。

第一，当前系统虽然已经具备打分、风险等级、代价评估等概念，但从实现上来看，这些更多是启发式聚合结果，主要服务于候选排序和展示，尚未形成一个足够独立、足够可论证的核心算法。

第二，系统当前的主要研究对象仍然是“生命科学任务 → 多 `Agent` 规划执行 → 工具调用 → 结果输出”。这意味着，即便加入了门控、人工决策、`patch/replan` 等机制，它在选题层面仍然会被看成“生命科学助手”的一部分或一部分的增强版，而非一个独立成立的计算机算法课题。

第三，当前系统的许多优点更多体现在“工程正确性”和“执行健壮性”上面。例如状态一致性、审计、恢复、人工确认等。这些无法突出算法上的创新，因此必须进一步回答：系统究竟依据什么做出关键治理决策，如何量化任务难度、执行风险和工作量，并据此改变执行路径。

小结 因此，对当前系统的总体判断可以概括为：当前系统已经具备成为实验平台和实验载体的条件，但是尚未形成一个足够清晰、足够独立的核心算法主线。它最大的风险是“研究对象还没有从生命科学助手（或蛋白质设计平台）提升为更底层、更通用的计算机问题”。如果不进行这一提升，那么即便继续为系统添加功能，也仍然可能被视为另一生命科学多 Agent 助手系统的补充或子集，而难以形成一个边界清晰、创新点明确的毕业设计选题。

2 当前选题面临的核心问题

在已有系统的基础上，当前毕设如果继续按原有思路推荐，其主要问题不在于“系统功能不够丰富”，而在于选题主线尚未完成从应用系统到研究问题的提升。这使得当前选题在创新性、独立性和答辩的可解释性方面都存在明显风险。

1. 缺少一个足够明确的核心算法问题 目前系统已经包含多 Agent 协作、显式状态机、HITL、`patch/replan`、蛋白质设计工作流等多个组成部分，但这些组成部分更多体现为一个较完整的执行平台，而不是一个被单独抽象和证明的算法对象。

换句话说，当前系统解决了“如何把流程跑起来”的问题，却没有清晰回答“系统依据什么原则做关键决策”这一更为核心的问题。尤其在以下方面，仍然缺少关键建模：

- 如何刻画任务难度
- 如何估计执行风险
- 如何衡量工作量与代价
- 如何在不同风险和预算条件下调整执行策略
- 如何决定是否值得自动执行、请求人工接入或直接恢复/终止

虽然当前已有部分门控和打分机制，但更多属于启发式聚合和排序，而不是一个足够独立、可被论证为“核心算法”的研究对象。

因此，如果按照当前路径继续推进，很可能被评价为缺乏足够集中、足够有辨识度的算法贡献。

2. 当前选题仍然容易被归入“生命科学助手”子集 已经有另一个同学的毕设是“生命科学助手”，同样采用多 Agent 架构。从架构相似性上来说，即便本系统已经具备一些机制，也很难天然摆脱“生命科学助手系统的一种更为复杂的实现”这一印象。

原因在于，当前系统的主要叙事仍然是：

用户提出生命科学任务 → 多 `Agent` 规划与执行调工具 → 返回结果

只要这个叙事不变，那么无论内部运行机制如何增强，它仍然有较大概率被看作生命科学助手的执行引擎、后端工作流或子模块。这对答辩会有很大风险。

因为该系统很难回答与已有的生命科学助手的本质区别、核心贡献是什么等这些问题。

3. 现有的增强机制更偏向工程健壮性，而非算法创新 当前系统中已经存在许多机制保证实验平台能力，但是从选题的角度去看，它们更多体现的是系统设计的正确性、运行治理等方面，没有进一步上升为统一的决策原理和算法问题。

4. 难度、工作量、风险尚未进入统一决策 此前反复讨论的关键词包括难度、工作量、风险、不确定性、成本和人工介入时机等，这些词都指向一个共同问题：系统缺少的不是更多功能，而是一个能够解释并驱动关键治理动作的统一决策框架。

如果没有这一框架，那么就无法体现为什么某个任务更难、为什么某个任务需要人工介入、为什么某条恢复链路比另一条更合适等问题。

小结 因此，当前选题面临的核心问题可以概括为三点：

第一，系统已经具备较完善的平台能力，但是尚未抽象出一个足够独立的核心算法问题。

第二，只要主叙事仍然停留在“生命科学领域的多 Agent 助手”，就难免被已经存在的父集系统覆盖。

第三，在当前时间约束下，必须尽快把研究对象从“继续扩展系统功能”转向“提炼一个可论证、可验证、可答辩”的核心问题。

也正因如此，后续的研究方向应该不再是“再加入什么能力”，而是究竟把当前系统上升为哪一个更为底层和独立的计算机专业课题的问题。

3 选题目标的重新定义

在前两部分的分析之后，可以看到，当前问题的关键不在于系统是否已经足够复杂，也不在于是否可以继续增加更多功能，而在于现有选题的研究对象需要重新定义。如果这一点不改变，那么后续的所有改进都很可能会继续停留在“把生命科学领域的多 Agent 助手做得更完善”这一层面上，而难以形成一个边界清晰、创新点集中、能独立成立的毕业设计选题。

因此，下一步重要的不是继续扩展原系统，而是转换到研究问题上。

从原有思路看，课题更容易被理解成：构建一个面向生命科学任务（蛋白质设计任务）的多 Agent 系统，通过规划、执行、工具调用和人工确认，帮助完成蛋白质设计任务等科研任务。这种表述的主语仍然是“生命科学助手”。一旦如此，无论其内部加入多少与运行机制，都仍然可能被视为一个更大助手系统中的一部分。也就是说，问题不在于这些机制本身是否重要，而在于它们没有被提升为一个更底层的研究对象。

要解决这一点，课题目标必须从“做一个生命科学助手”转向“研究高代价科学工作流如何被控制”。这一变化在明确毕设的边界。一旦采用新的表述，系统的核心问题就不再是“如何理解生命科学任务并给出结果”，而变成了“在一个代价高、链路长、存在失败与恢复、且允许人工介入的科学工作流中，系统应该依据什么原则决定下一步如何推进”。这样，系统关注的重点也会发生变化：难度、风险、恢复空间、人工介入时机等因素，不再是辅助性的描述目标，而是会成为驱动执行策略变化的核心决策变量。课题的重点就从一个助手或系统，转变成运行时控制与治理机制。

我认为这一重新定义是重要的，因为它同时解决了三个问题：

首先，它能够把课题从一个应用层面的生命科学助手，提升为一个更加通用的计算机问题。只要研究对象被定义成“高代价科学工作流控制”，那么蛋白质设计就不再是

课题本体，而只是一个验证场景。这样做的意义在于，系统的核心方法理论上不仅可以服务于蛋白质设计，也可以扩展到其他科学工作流场景，例如复杂文献调研、材料设计或多阶段实验分析。也就是说，课题不再被一个具体应用锁死，而开始具备“方法先于场景”的结构。

其次，这种重新定义有助于切断与“生命科学助手”父集之间的包含关系。如果别人的系统关注的是“如何面向生命科学系统提供智能帮助”，而当前课题关注的是“如何控制高代价工作流的执行、恢复与人工介入”，那么两者的层级就已经不同。前者关注任务入口和任务处理，后者关注治理逻辑。此时，生命科学助手可以被视为该课题的上层入口，而不是父集。这种关系转换对于选题的独立性尤其重要。

再次，从计算机专业毕设的角度去看，这种重新定义也容易形成明确的算法主线。一旦将命题定义为“工作流控制”，就必须回答一系列典型的计算机问题：系统状态如何表示，哪些变量是不可直接观测的，运行时观测如何更新系统判断，动作空间如何定义，目标函数如何刻画成本、风险和收益之间的平衡，以及在有限预算和不确定性条件下系统如何做出决策。这些问题天然带有控制、调度、约束优化和序贯决策的特征，明显比“继续扩展生命科学助手能力”更接近一个可论证的研究方向。

在这一基础上，新的目标可以概括为：**不再把毕设定义为生命科学多 Agent 助手，而是定义为面向高代价工作流的运行时治理与控制问题，并以蛋白质设计场景为验证对象**。这一目标意味着，现有系统的角色也在随之变化。它不再是毕设本身的全部内容，而是一个实验平台和运行载体。那么，该系统中采用的 FSM、HITL、patch/replan、候选与实验框架等，都不再是零散功能，而是成为后续控制算法可依附的基础环境。换句话说，真正的研究主题转移到该系统之上的运行时控制层。

另外比较重要的是，剩余的周期已经不足两个月。此时及时把目标收缩到“高代价科学工作流如何控制”这一更为聚焦的问题上，那么后续工作将更容易围绕一个明确的主线展开：系统状态如何抽象，难度和风险如何进入决策闭环，控制器如何决定继续执行、恢复、人工介入或终止，以及这种控制相对静态流程究竟能带来什么收益。这样一来，剩余时间更有可能形成一个完整且可答辩的结果。

小结 因此，当前毕设需要一次本质上的选题重构，即从“生命科学多 Agent 系统”转向“面向高代价科学工作流的运行时控制问题”。蛋白质设计仍是其重要的应用场景，但它不再是课题定义本身。只有完成这一层转换，后续关于创新点与可行性的讨论才具有意义。也只有在这一前提下，该课题才可能摆脱被父集系统覆盖的风险，成为一个边界清晰、问题集中、具备算法含量的毕设。

4 候选方向比较

在完成选题的重新定义之后，接下来的问题是在可选的研究方向中，哪一条最适合在当前时间、已有系统基础和答辩要求下收敛成一个成立的毕设课题。从目前的讨论来看，真正有代表性的方向大致可以分成四类：继续沿蛋白质设计系统增强路线推进、转

向自动 benchmark、转向工作流编译/验证/修复，以及转向运行时 controller。它们分别对应不同的研究对象、不同的创新重心，也对应不同的风险。

4.1 延续“蛋白质设计系统增强”路线

这是与当前系统最接近的一条路线。其基本思路是继续围绕生命科学任务展开，将系统定义为一个面向蛋白质设计或更广义生命科学任务的多 Agent 助手，并再次基础上不断补充能力，例如更完整的工作链、更复杂的任务拆解、更细致的门控、更丰富的 HITL 交互，以及更完善的恢复逻辑。

这一条路线的核心是：把系统当作应用产品或综合平台来完善。其关注重点在于系统覆盖了多少能力、能处理多少真实请求、交互链路是否顺畅、执行流程是否稳定。它的优势十分明显：与现有系统最贴近，实现成本最低，也最容易展示出成果。

但它的问题同样明显。首先，这条线路最容易被看成是另一个生命科学助手的自然扩展。因为只要系统的对外叙事仍然是“面向生命科学任务（蛋白质设计）的多 Agent 帮助系统”，那么内部无论加入多少状态机、恢复机制和人工确认逻辑，本质上都没有脱离“助手系统”这一概念。其次，这一条路径的创新点很难集中，往往会分散在多个工程增强点上，例如增加某一类工具、改进某一段流程或补充某种门控逻辑。这些内容单独来看都合理，但是很难压缩成一个明确的算法主线。最后，在当前时间压力下，继续走“大系统增强”的路线很容易导致内容越做越多，主线却越来越模糊。

因此，虽然这条路线工程上最平滑，但是从毕设选题的角度来看，它恰恰是风险最高的一条，因为它最容易落入无法解释核心研究问题是什么的局面。

4.2 自动 Benchmark 路线

自动 benchmark 路线的思路是把研究对象从“如何更好地完成任务”转向“如何系统地评测复杂科学工作流任务”。在这一方向上，系统不再首先关注“输出什么结果”，而是关注：如何构造具有不同复杂度和难度层级的任务，如何让这些任务可复现、可比较、可自动评分，以及如何让 benchmark 真正反映多 Agent 系统在高代价科学工作任务中的能力差异。

从近两年的研究趋势来看，这条路线是成立的，而且学术价值很明确。

PaperBench [1]

5 选择 Belief-State Controller

6 Belief-State Controller 问题定义

7 相关研究现状

8 可能的创新点、难点

9 可行性分析

10 预期结果

11 风险与备选方案